

Analyse sociodémographique des étudiants d'Openclassrooms

Parcours DATA

Contexte et objectifs

- Analyser l'évolution du profil sociodémographique des étudiants des parcours Data sur 4 ans (2022–2025)
- Objectiver les tendances en termes de genre, âge et région
- Comparer le profil OC à la population française (données INSEE)
- Alimenter les réflexions stratégiques sur l'accessibilité et l'égalité des chances

Sources de données

OPENCLASSROOMS (Données Internes)

Source

Extraction des inscriptions aux parcours Data Analyst
Données nettoyées et pré-agrégées

Période

2022-2025

Variables Clés

USER_ID
PATH_CATEGORY_NAME
AGE_GROUP
GENDER
REGION
YEAR_PATH_STARTED



INSEE (Données Publiques)

Source

Données démographiques régionales officielles
Référentiel annuel de population des années 2022 à 2025

Période


2022-2025

Variables Contextuelles


ANNEE
REGION
SEXE
AGE
POPULATION



Workflow



Pipeline DBT



RAW

Ingestion de
données brutes
(OC + INSEE)



STAGING

Nettoyage et
Normalisation



INTERMEDIATE

Standardisation des
tables avant la
création de la table
finale



MART

Table finale
pour l'analyse

Sources et qualité

4647

Inscriptions brutes

4010

Étudiants uniques

13

Régions

4

Années

OPENCCLASSROOMS

- YEAR_PATH_STARTED → ANNEE
- AGE_GROUP → AGE
- GENDER → SEXE
 - valeurs manquantes :
NULL → 'Non renseigné'
- REGION
 - harmonisation :
DROM → DOM
Centre-Val de Loire → Centre-Val-de-Loire

INSEE

- REGION :
 - conserver les agrégats voulus
- AGE :
 - harmonisation des tranches d'âge :
30 à 34 ans → 30-34 ans
 - enlever des classes
 - agrégation de classes pour la classe
"60 ans ou plus"

Conformité RGPD

Minimisation des données

- Seules les variables utiles à l'analyse ont été conservées
- Aucune donnée directement identifiante (nom, prénom, email) n'est présente dans les tables finales

Finalité déterminée

- Le pipeline DBT produit des tables agrégées, jamais de données individuelles en sortie

Tranche d'âge

- Les Tranches d'âges permettent d'optimiser l'anonymat des étudiants


Données INSEE (publiques)

- Les données INSEE sont des statistiques agrégées de population, aucune contrainte RGPD applicable

Un parcours qui attire moins

ÉVOLUTION DES INSCRIPTIONS 2022-2025

Évolution du nombre d'étudiants OC



2022

1 696 inscrits

2023

Repli de 32%

2024

Repli de 26%


2025

Augmentation de 12%

Les femmes restent sous-représentées

RÉPARTITION PAR GENRE DES ÉTUDIANTS

Répartition globale




Évolution de la parité H/F (2022-2025)




Une majorité de jeunes adultes

ANALYSE DE LA POPULATION D'ÉTUDIANTS PAR ÂGE

Répartition par âge et genre (Total)




Évolution du profil d'âge des inscrits (2022-2025)




L'Île-de-France berceau du parcours data

ANALYSE DE LA POPULATION D'ÉTUDIANTS PAR RÉGION

Répartition par région et genre (Total)



Taux d'étudiants (pour 10 000 habitants)



Recommandations stratégiques

Renforcer l'attractivité féminine

- Développer des communications et partenariats ciblés (associations féminines dans la tech, témoignages d'alumni)

- Objectifs :

Court terme (3 ans) : porter la part féminine au-delà de 40 %

Moyen terme (5 ans) : atteindre la parité

Adresser les territoires sous-représentés

- Partenariats avec les régions pour le financement de la formation
- Partenariat avec centre de formation régionale type GRETA

Rajeunir l'audience

- Partenariats avec des universités et lycées
- La tendance 2022 -2025 (20-24 ans : +7,3%) confirme la faisabilité
- Campagne marketing sur les réseaux sociaux (Instagram, Tik Tok...)

Mettre à jour le pipeline annuellement

- Automatiser l'ingestion des données INSEE dans Snowflake
- Prévoir un tableau de bord de suivi live connecté aux tables DBT

Reproductibilité et limites

Ce que le pipeline garantit

- Reproductibilité : "dbt run" produit les mêmes résultats à chaque exécution
- Intégrité : tests DBT automatiques (unique, not_null, accepted_values)
- Traçabilité : chaque modèle est versionné et documenté en YAML
- Conformité RGPD : pas de données personnelles dans les tables finales

Limites à connaître

- Genres non renseignés : analyse genre partielle
- Région déclarée à l'inscription : peut ne pas refléter la résidence réelle
- Pas de données sur le taux de réussite ou d'abandon par profil
- Pas de données détaillées sur les étudiants inscrits plusieurs fois

CONCLUSION

Le profil type de l'étudiant OpenClassrooms (parcours data)

- Majoritairement masculin
- Concentré en Île-de-France
- Âgé de 25 à 39 ans principalement

Axes d'amélioration prioritaires

- Féminisation du public
- Accessibilité territoriale
- Rajeunissement de l'audience
- Pipeline à actualiser annuellement
- Enrichir avec données de réussite