



Détection de faux billets

ORGANISATION NATIONALE DE LUTTE CONTRE LE FAUX-MONNAYAGE

Contexte & objectif



Mission de l'ONCFM

Organisation publique chargée d'identifier les contrefaçons de billets.



Problématique

Construire un algorithme capable de différencier automatiquement un vrai d'un faux billet, à partir de ses seules caractéristiques géométriques



Enjeu métier

Détecter un maximum de faux billets : la priorité est donnée au recall sur la classe « Faux », plutôt qu'à la seule accuracy globale

Le jeu de données

1 500

billets analysés

6

variables géométriques

1 000

vrais billets (66,7 %)

500

faux billets (33,3 %)

`length`

Longueur du billet (mm)

`height_right`

Hauteur mesurée côté droit (mm)

`margin_low`

Marge entre le bord inférieur et l'image (mm)

`height_left`

Hauteur mesurée côté gauche (mm)

`margin_up`


Marge entre le bord supérieur et l'image (mm)

`diagonal`

Diagonale du billet (mm)

Analyse exploratoire — dimensions clés

Moyennes par catégorie de billet : les vrais et les faux billets se distinguent nettement sur 3 variables




Les faux billets ont leurs marges (haute et basse) plus larges, en particulier la marge inférieure (5,22 mm vs 4,12 mm) et sont en moyenne plus courts (111,63 mm vs 113,20 mm).

Ces 3 variables se dégagent des boxplots comme les plus discriminantes.

Analyse exploratoire — corrélation avec la cible

Corrélation de chaque variable géométrique avec `is_genuine` (1 = vrai, 0 = faux)



Interprétation

length : 0,85

Corrélation forte positive — le meilleur indicateur pris seul

margin_low : -0,78

Corrélation forte negative

diagonal : 0,13

Quasiment aucune relation linéaire avec la cible : la diagonale, seule, ne permet pas de différencier efficacement un vrai billet d'un faux

Préparation des données

1

Traitement des valeurs manquantes

Imputation par la médiane (colonne `margin_low` -> 37 valeurs manquantes), calculée sur le train puis appliquée au test — sans fuite de données.

2

Séparation train / test

Split stratifié 80 / 20 : 1200 billets pour l'entraînement, 300 pour le test. La proportion vrais/faux (66,7 % / 33,3 %) est conservée dans les deux jeux.

3

Standardisation

Mise à l'échelle des variables (moyenne 0, écart-type 1), indispensable pour la régression logistique, le KNN et le K-means — pas nécessaire pour le Random Forest.

Méthodologie — 4 approches mises en concurrence

Régression logistique

Supervisé

Modèle linéaire de classification binaire, rapide et interprétable.

KNN (K-Nearest Neighbors)

Supervisé

Classe un billet selon la classe majoritaire de ses k plus proches voisins.

Random Forest

Supervisé

Ensemble d'arbres de décision, robuste aux relations non linéaires.

K-means

Non supervisé

Regroupe les billets en 2 clusters à partir des seules distances géométriques.

Résultats des modèles supervisés

Évalués sur le jeu de test (300 billets : 100 faux / 200 vrais)

Modèle	Accuracy	Précision (Faux)	Recall (Faux)	F1-score (Faux)
Régression logistique	0.99	0.9899	0.98	0.9849
KNN	0.9833	0.9798	0.97	0.9749
Random Forest	0.99	0.9899	0.98	0.9849


- La régression logistique et le Random Forest arrivent en tête, ex æquo sur toutes les métriques (accuracy 0,99 — recall Faux 0,9899).
- Le KNN reste performant (accuracy 0,9833) mais légèrement en retrait sur la détection des faux billets.
- Le critère décisif pour l'ONCFM : le Recall (Faux), qui mesure la part de faux billets réellement détectés.

Résultats de l'approche non supervisée — K-means

0,344

Coefficient de silhouette

Séparation modérée des 2 clusters :
structure statistiquement pertinente,
avec une zone de chevauchement
géométrique.



Comparaison avec le supervisé

Malgré l'absence de la variable cible pendant l'entraînement, le K-means atteint des performances proches de la Régression Logistique et du Random Forest sur ce jeu de données.

	Faux (réel)	Vrai (réel)	Total
Cluster 0	388	6	394
Cluster 1	12	794	806

Comparaison finale des 4 modèles

Le critère décisif : Recall (Faux), le plus proche possible de 1,00


Modèle	Accuracy	Précision (Faux)	Recall (Faux)	F1 (Faux)	Retenu ?
Régression logistique	0.99	0.9899	0.98	0.9849	✗
KNN	0.9833	0.9798	0.97	0.9749	✗
Random Forest	0.99	0.9899	0.98	0.9849	✓
K-means (non supervisé)	0.9867	0.98	0.98	0.98	✗

Le Random Forest et la Régression logistique obtiennent des performances identiques.

Le Random Forest est retenu comme modèle final : il ne nécessite pas de standardisation, il est plus robuste face à des données futures légèrement différentes, et il fournit une importance des variables directement exploitable.

Modèle retenu : Random Forest

Importance des variables dans la décision du modèle



length porte à elle seule environ 50 % du pouvoir prédictif du modèle.

margin_low en 2^e position porte environ 31 % du pouvoir prédictif du modèle.

Ces résultats confirment l'analyse exploratoire des corrélations réalisée en amont.

diagonal n'apporte quasiment aucune information au modèle.


Optimisation du seuil de decision

GridSearchCV (optimisation du recall Faux) puis ajustement du seuil de probabilité de prédiction

Seuil	Recall (Faux)	Précision (Faux)
0,50	0.970	0.990
0,60	0.980	0.980
0,70	0.980	0.980
0,80	1.000	0.952
0,90	1.000	0.926

Arbitrage : au-delà du seuil 0,80, le recall n'augmente plus (déjà à 1,000) alors que la précision continue de baisser — 0,80 est donc l'optimum métier

Pour un seuil de 0,80 :
Recall (Faux) = 1,000 → aucun faux billet n'est classé comme vrai.
Précision (Faux) = 0,952 → encore élevée : peu de vrais billets faussement rejetés.
Le billet n'est classé « vrai » que si le modèle est sûr à 80 % ou plus, un choix cohérent avec l'enjeu prioritaire de l'ONCFM : ne laisser passer aucune contrefaçon.



Conclusion & recommandations

Résultats clés

Random Forest retenu, avec seuil optimisé à 0,80 :

recall (Faux) = 1,000 / précision (Faux) = 0,952

length et margin_low sont les 2 variables les plus discriminantes

Limites

Jeu de données de taille modeste (1 500 billets)

Surveiller sur des volumes plus importants en production

Perspectives

Déploiement du modèle Random Forest optimisé au sein d'une application de production (script prenant en entrée un billet ou un fichier billets_production.csv).

Réévaluation périodique du modèle à mesure que de nouveaux billets (et nouvelles contrefaçons) sont collectés.

Présentation des applications

Ligne de commande

Prérequis pour faire tourner le script :

Python 3.8 ou +

Les librairies suivantes :

- `pandas`
- `numpy`
- `joblib`

Les informations pour lancer le script se trouvent dans README_app.md

```
False 172.52 104.48 104.17 5.16 3.39 110.71 0.00 Faux
False 172.47 104.16 103.85 3.99 3.32 111.25 0.26 Faux
False 171.30 104.49 103.89 4.88 3.17 111.51 0.00 Faux
False 171.78 103.93 103.93 5.88 3.19 111.07 0.00 Faux
False 172.11 104.14 104.15 4.84 3.28 110.98 0.00 Faux
False 171.82 104.32 104.05 6.06 3.03 111.68 0.00 Faux
False 171.79 104.18 104.54 5.13 3.51 112.40 0.00 Faux
False 172.01 103.97 104.40 5.52 3.31 111.18 0.00 Faux
False 171.63 104.33 104.61 4.88 3.35 112.16 0.00 Faux
False 171.57 104.14 104.14 5.41 3.23 111.76 0.00 Faux
False 171.75 104.38 104.17 4.42 3.09 111.28 0.02 Faux
False 172.19 104.63 104.44 5.27 3.37 110.97 0.00 Faux
False 171.80 104.01 104.12 5.51 3.36 111.95 0.00 Faux
False 172.06 104.28 104.06 5.17 3.46 112.25 0.00 Faux
False 171.47 104.15 103.82 4.63 3.37 112.07 0.08 Faux

Résumé : 1500 billet(s) analysé(s) - 995 vrai(s), 505 faux.
Seuil de décision utilisé : 0.8
Résultats sauvegardés dans : resultats.csv
```

Application web avec Streamlit


Prérequis pour lancer l'application web :

Python 3.10 ou +

Les librairies suivantes :

- `pandas`
- `numpy`
- `joblib`
- `scikit-learn`

Les informations pour utiliser le script se trouvent dans README_app_streamlit.md



Exportation des résultats dans un fichier nommé resultats.csv